

有远见和令人印象深刻 - 但也有弹性？ 对海蒂“可见学习”方法论的批判

Christof Wecker · Freydis Vogel · Andreas Hetmanek

在线发布:2016年11月9日
© Springer Fachmedien Wiesbaden 2016

总结John Hattie的《可见学习》一书在德语世界引发了广泛的反响,甚至在公共媒体上也是如此。迄今为止,有关这方面的教育科学讨论占据了优先地位

处理实质性和更全球性的方法学问题,但仍需对方法学进行详细的批判性考虑。在这篇文章中

我们解释了 Hattie 选择的元分析方法的方法要求,并测量了所使用的数据基础及其

具体程序。此外,我们批判性地检查了哈蒂方法的基本充分性。他全面整合实证教育研究的方法被证明是有远见的,

但在目前的出版条件下不科学可行的。因此,我们建议集中独立于期刊出版物的实证研究的方法和结果

收集标准化和元分析可用形式的数据库和使可访问。

PD博士C. Wecker (实证)
教育学和教育心理学,路德维希-马克西米利安-慕尼黑大学,
Leopoldstrasse 13, 80802 慕尼黑, 德国
电子邮件:christof.wecker@psy.lmu.de

F. 沃格尔博士
慕尼黑工业大学教育学院, Arcissstrasse 21, 80333 Munich,
德国
电子邮件:freydis.vogel@tum.de

致 A. Hetman 博士
实证教育学和教育心理学,路德维希-马克西米利安大学慕尼黑,
Leopoldstrasse 13, 80802 慕尼黑, 德国
电子邮件:andreas.hetmanek@psy.lmu.de

关键词循证实践 证据数据库 Hattie

元分析·元合成

有远见和令人印象深刻 但也可靠？

对海蒂 “可见学习”方法论的批判

摘要在德语国家,约翰·海蒂 (John Hattie)的《可见学习》一书甚至在公共媒体上也引起了广泛的共鸣。迄今为止,教育研究的讨论主要涉及实质性的、相当全局的方法论问题,而对方法论的详细批判性评价仍然缺乏。在本文中,我们阐述了 Hattie 选择的元分析方法的方法要求,并使用它们来评估底层数据库以及他的具体程序。此外,我们在原则上批判性地讨论了海蒂方法的适当性。事实证明,考虑到当前的出版实践,他全面整合实证教育研究的方法,尽管是有远见的,但以科学合理的方式是不可行的。因此,我们建议收集实证研究的方法和结果无论文期刊出版物如何 并以标准化和元分析可用的格式在中央数据库中提供它们。

关键词循证实践 · 证据数据库 · Hattie · 荟萃分析 ·
元合成

1 关于 “海蒂研究”的讨论

约翰·海蒂的《可见学习》一书在德语国家引发了广泛的反响,甚至在公共媒体上也是如此。使用创新方法,对认知学习成果的 138 个影响因素的 800 多项荟萃分析的结果在 “二级”荟萃分析中进行了总结。除了内容问题外,教育科学对此的讨论主要涉及工作的更多全球方法方面。

这里所表达的批评尤其应在科学理论辩论的背景下看待,即元分析在获取知识方面的地位和适用性:例如,人们怀疑元分析 “基于文献研究” 可以像 “基于对自然的研究” (Sohn 1995,第 109 页)的初级研究一样,对知识的获取做出贡献。有人反驳说,每项荟萃分析都只是收集和总结了大量关于同一主题的主要研究的证据 (Lipsey and Wilson 1995, p. 113 f.) ,但绝不会 “达到另一个层次” 。并从认知对象本身中移除。因此,针对 Hattie 工作的一些反对意见是对荟萃分析的标准批评的一部分:有人批评说,概述工作类似于 “从空中拍摄的广角照片 [...]不再被认可 (Brügelmann 2014,第 48 页;见

Terhart 2011, 第 436 页)。在不同研究中理解不同并且由不同教师以不同方式实施的测量的效果大小被总结为不同研究之间的学习成功测量 (Brügelmann 2014, p. 42 f.; Snook et al. 2009, p. 96 起)。在不同情况下可能产生不同影响的措施的影响也将减少到平均影响大小 (Snook 等人 2009, p. 96; Brügelmann 2014, p. 39 ff.)。此外, Hattie 没有提供任何关于纳入的荟萃分析质量和它们所依据的主要研究的信息; 最重要的是, 所包含的荟萃分析的质量标准各不相同 (Snook 等人 2009 年, 第 94 页 ff.; Terhart 2011 年, 第 429 页; Brügelmann 2014 年, 第 41 页; Pant 2014a, 第 93 页)。, 2014b, p. 142)。; Beywl 和 Zierer 2015b, p. XIII)。

缺乏对现有初级研究的报道也受到批评: 一方面, 没有显着结果或效应量小的研究发表频率较低 (Snook et al. 2009, p. 97; Brügelmann 2014, p. 41 f.; Beywl and Zierer 2015b, p. XIII), 另一方面, 定性研究通常不被考虑在内 (Terhart 2011, p. 426; Brügelmann 2014, p. 42; Beywl and Zierer 2015b, p. XII)。对于一级荟萃分析, 这些批评中的大多数都可以反驳 (Borenstein et al. 2009, p. 378 ff.)。然而, 这并不意味着此类问题不会在二级荟萃分析水平上以新的形式出现, 例如当纳入标准必须比一级荟萃分析更广泛地定义时为了能够总结足够数量的此类荟萃分析, 从而加强“广角”特征, 或者如果不仅措施的操作化在实施的主要研究之间有所不同, 而且元数据之间的措施类型的定义也进行分析。

对 Hattie 工作的更具体批评是文献已经过时 (Terhart 2011, p. 428; Brügelmann 2014, p. 45; Beywl and Zierer 2015b, p. XIV), 或者包含的元数据中的主要研究范围没有考虑分析 (Arnold 2011, p. 220; Brügelmann 2014, p. 41; Pant 2014a, p. 94 f.; 2014b, p. 142 ff.)。对定量可测量变量和认知学习成果的关注, 而非认知学习成果被忽视, 也受到批评 (Snook et al. 2009, p. 95 f.; Terhart 2011, p. 426; Brügelmann 2014, p. 43; Beywl and Zierer 2015b, p. XI f.)。此外, 结果的跨国界转移性, 尤其是对德国教育系统的转移性受到质疑 (Snook et al. 2009, p. 97 f.; Brügelmann 2014, p. 43 ff.; Beywl and Zierer 2015b, p. 十四至十六)。哈蒂的一些与内容相关的结果也受到质疑, 例如发现制度框架条件起着相当小的作用 (Snook et al. 2009, p. 98 ff.; Brügelmann 2014, p. 47 f.)。总体而言, 一些批评者还认为, 过度选择性和扭曲的接受可能会支持先入为主的观点 (Snook et al. 2009, p. 104)。

作为对教育科学讨论中这些更全球性的方法论或主要与内容相关的主题的补充和补充, 对哈蒂方法论的详细审查仍有待进行。这就是这个贡献的目的。首先, 让我们找出哪些

数据基础的方法学标准和海蒂的方法

他所选择的方法中的任何一个都将被应用（第 2 节）。在主要部分中,我们区分了对数据基础的批评（第 3.1 节）即

来自包含的荟萃分析的信息及其基础

撒谎的初级研究 以及根据他自己的标准衡量的对海蒂方法的“内部”批评（第 3.2 节）。之后我们讨论

“外部”批评 所选方法的基本充分性

（第 3.3 节）,在我们最终解决已确定的批评点（第 4 节）的可能后果之前。从“可见”中给出的例子

学习”始终不代表任何“在艰苦的详细工作中发现的错误”。相反,它们被选为示例,其方式是

用它们来重构海蒂的方法及其系统缺陷

讲清楚。因此,我们通常不会提供进一步的文件。假如

一个例子并不代表一个系统的方法,这是来自

文本。

2 二级荟萃分析的方法论基础

迄今为止,教育和相关领域的二级荟萃分析的例子很少（例如,Sipe 和 Curlette 1997; Peterson 2001;

威尔逊和利普西2001;塔米姆等人。 2011）,几乎没有任何方法论工作,在

为此类调查程序制定了哪些标准

（例如 Sipe 和 Curlette 1997,第 602 页以下）。因此,我们首先根据 Hattie 选择的基本假设来制定要应用的方法标准

有条不紊的方法。

根据 Hattie 的工作,它是荟萃分析的“综合”

(Hattie 2009, p. 3 ff.) 或“荟萃分析” (Hattie 2009, p. 3)。

应用了固定效应模型 (Hattie 2009,第 12 页)。中央

采用固定效应模型表明所有主要研究都有一个常数

“真实”效应大小很常见。不同的效果大小,反映在

通常,在个别初级研究中出现,因此完全是由于初级研究中的抽样

与共同常数效应大小的随机偏差。这

因此,根据主要研究中的样本确定的效应量继续存在

来自恒定共同效应大小和抽样误差的加法

一起。因此,在初级研究中确定的效应大小是具有概率分布（样本特征值分布）的随机变量,

其散布取决于样本大小:样本越大,一个

初级研究中,这种分布的分布越小。基于大

主要研究,因此可以更精确地估计恒定联合效应大小（例如 Hedges 和 Olkin 1985,第 107 页;

Borenstein 等人, 2009,

S. 63 ff.）。

因此,当在荟萃分析中估计共同的恒定效应大小时,各个主要研究根据它们的分类在固定效应模型中

精度,即与样本特征值分布的方差成正比

它们的影响大小,加权(见附录中的公式 1 或 5)。有可能的
反过来确定联合常数效应大小的新估计的精度,该估计现在基于所有主要研究的效应大小。

在固定效应模型中,它们的精度完全取决于
个别研究中效应大小的样本参数分布
(见附录中的公式 2 或 6)。

因此,固定效应模型框架内的荟萃分析
甚至像有效应大小估计及其方差的初步研究
处理并纳入二级荟萃分析。只要主要研究实际上具有共同的恒定效应大小,

是这样一个基于几个的二级固定效应荟萃分析
Meta 分析相当于一级固定效应 Meta 分析
所有主要研究的基础(证据:见附录)。在荟萃分析中
第二级,纳入的荟萃分析类似于
根据精确度对普通荟萃分析进行加权;联合常数效应大小的总体估计精度也是

以类似方式确定(参见附录中的等式 7 至 9)。

该程序充分性的一个关键条件是
- 就像在一级荟萃分析中一样 - 的统计独立性
基本估计。总结的一级荟萃分析
因此,它们所依据的主要研究不得重叠
(参见 Sipe 和 Curlette 1997,第 624 页)。

这导致了以下方法论要求,Hattie 的工作将根据这些要求进行衡量:(1)在考虑的荟萃分析
中,
正确确定主要研究的效应大小和方差的基础
在固定效应模型的框架内正确加权,共同常数效应强度及其方差必须已经确定。(2)在荟萃分析
中
第二级必须基于在所使用的主要研究中不重叠的荟萃分析,并且在框架中具有正确的权重

固定效应模型的共同常数效应强度及其方差
待确定。这两个要求是以下原因
已经提到了对数据基础的批评之间的分离
以及对海蒂行为的“内部”批评。

3 对“可见学习”方法的批评

3.1 对数据基础的批评

首先,我们解决Hattie的数据基础在多大程度上与Sect中提到的数据基础相对应的问题。2 制定有条理的要求(见表1)。在
在基础一级荟萃分析中包含的单个主要研究效果水平,必须首先正确确定单个主要研究效果强度。首先,必须做出决定

是否满足实验条件和控制条件的平均差
两个条件的合并标准差

Tab. 1个别分析步骤的不足

分析步骤	方法的缺陷
数据基础:基础一级荟萃分析	
(1) 计算每个 包括 主要研究效果	交替使用 Cohen 的d或 Hedges 的g与 Glass 使用 标准误差而不是标准差
(2) 总结 内的主要研究效果 使用的荟萃分析 第一阶段	根据其精确度缺少主要研究的权重 缺少有关估计联合效应大小方差的信息（方差、标准误差或置信区间） 改为说明主要研究效应的标准差 估计的方差（或标准误差）的信息 共同效应量 缺少主要学习桌 主要研究表中缺少信息,尤其是在实验和对照条件下的样本量
方法：“可见学习”中的二级荟萃分析	
(1) 遵守 纳入标准	纳入来自荟萃分析的个体效应量估计 第一级,其中还包括对超出性能范围的变量的影响 一阶荟萃分析错误归因于 影响因素
(2) 从荟萃分析中确定效应大小 第一阶段	汇总时使用相关系数 一级荟萃分析中的相关效应大小 而不是 Fisher 的 z 分数
(3) 差异的确定 效应量估计 首先从荟萃分析 步	尽管没有使用或计算标准误差 一级荟萃分析中的足够信息 根据一级荟萃分析中效应量标准差的信息而不是主要研究中的样本量信息计算标准误差 不正确
(4) 重复中和	缺少对具有重叠集的一级荟萃分析之间的统计相关性的考虑 来自初级研究
(5) 加权估计 效果强度	来自一级荟萃分析的效应量的未加权总结
(6) 确定 的标准误 效应大小估计 置信区间 （或显著性检验）	使用标准误的算术平均值 一级荟萃分析作为荟萃分析中的标准误差 在第二阶段确定的效应量估计 二级荟萃分析中确定的效应量估计值的显著性检验和置信区间计算

如 Cohen 的d,Hedges 的g或 Hedges 的标准化均值差的无偏估计量,或 Glass 中控制条件的标准差（Hedges and Olkin 1985, p. 78 ff.; Rosenthal 1994,

第 236 页以下）。这两个变体中的任何一个都不一定比另一个更可取。在第二次荟萃分析中的后续总结有问题

但是,如果第一级的荟萃分析不使用相同的效应量测量,则它是水平的,因为提到的测量没有相互转换

能够。例如,在 Nes 的荟萃分析中

bit 和 Adesope (2006, p. 423) 相对于合并标准差,在另一方面, Horton 及其同事 (1993,第 97 页)的标准差从控制条件。特别是当平均值有很大差异时和实验和控制条件之间的标准偏差,以及显着更大的实验组,这些效应大小测量值可能会很明显彼此不同。

关于正确确定主要研究效果大小的另一个问题是标准偏差和标准误差之间的孤立混淆

Eisenstaedt 等人的主要研究中的第一个因变量。(1990 年)在 Gibels 等人中。(2005 年,附录,第 56 页)给出为 -8.291。尽管提到几个这样的极端值 (Gijbels et al. 2005, p. 43)并不明显,这些是如何处理的。错误的来源在这里很明显:在原始出版物用于实验组中的变量“Exam 1”算术平均值为 66.53,标准误差 (SE) 为 2.74 和对照组的算术平均值为 80.21,标准误差为 1.65 (第 S12 页,表 1)。在确定效果大小时,显然不是标准差的标准误差对照组分裂: $(80.21 - 66.53) / 1.65 = -8.291$ 。由于对照组的样本包括 107 人 (Eisenstaedt 等人 1990, p.S12),他们的标准偏差 17.07 (参见 Bortz 2005, p. 90, equation 3.1)和 Glass 因此 -0.80。

此外,主要研究的效应量也出现在荟萃分析中有时在没有可识别的系统学的情况下计算不正确。Spies (1987)和

Fisher (1992)在两项荟萃分析涵盖的几乎所有主要研究中都发现了明显的差异。例如,对于 Dansky 的主要研究 (1980)报告了 Fisher 的效应大小为 $r = 0.428$ (第 166 页,表 1)另一方面,间谍有几个单独的相关性,所有这些都是 $r = 0.62$ 或更大 (表 2)。

在所使用的一级荟萃分析中,在主要研究效果的总结层面还有进一步的错误来源。一方面,将

在一些荟萃分析中估计联合效应大小时没有

主要研究根据其精确度进行加权。关于主题

“辅助辅助工具”来自 Hattie,用于 Levie 和 Lentz 的荟萃分析

(1982)显然来自“学习”部分的 0.55 效应量

插图文本信息”(第 198 页);然而,这是表 1 中 24 个效应量的未加权算术平均值 (第 199 页)。虽然在这里

根据表 1 中可能的信息,正确估计

通过对主要研究进行加权来确定组合效应大小。

另一方面,适当的权重需要进行一级荟萃分析

在二级荟萃分析中,估计的共同效应大小的方差是必要的 (见第 2 节)。它可用于任何一级荟萃分析

确定是否给出了效应量估计的标准误差。这个

反过来,可以从置信区间确定。¹但是,在某些荟萃分析中找不到这些精度度量。例如,这适用

关于 Levie 和 Lentz (1982, p. 198)荟萃分析的“辅助工具”主题,然而,其中的方差来自样本量的信息至少可以大致确定初级学习表。其他案例仅用于很少的精度,而不是可用的精度度量主要研究效果的有意义的标准偏差(例如 Lee 和 Genovese 1988,第 282 页)。

如果任何荟萃分析,提到的大多数问题都可以解决第一级将包含一个完整的表格,其中包含所有涉及的主要研究。然而,情况往往并非如此,因为在这两种情况下海蒂引用了关于“间隔与大规模实践”主题的荟萃分析(Lee 和吉诺维斯1988;多诺万和拉多舍维奇1999)。即使包含一个主要研究表,它也经常缺乏必要的信息,尤其是关于实验和控制条件下的样本量,例如受试者 White (1988, p. 367, Table 1)的荟萃分析中的“直接指导”。总之,可以说 Hattie 已经上市了

数据基础在很多方面都存在不足。

3.2 方法论的内部批评

我们现在转向哈蒂工作中如何计算的问题满足他所选择的方法要求方法(见表1)。

(1)符合纳入标准。根据海蒂自己的数据(2009 年, p. 15)对认知表现领域(“学术成就”)影响的研究现状进行总结。不过,也有一些

来自荟萃分析的效应量没有或没有完全包括在内分配到服务区。例如,在游戏的条件下,Hattie 采用了 Fisher (1992, p. 168)荟萃分析的整体效应大小 $r = 0.347$ - 转换为 $d = 0.74$ (Hattie 2009,附录 A) - 这也会影响从“视角”和“监管”两个方面谈“社会发展”影响”(Fisher 1992,第 175 页,表 3)。

由于 Hattie 对每个影响因素进行了单独的二级荟萃分析,因此有关自变量的进一步纳入标准隐含地适用于它们中的每一个。有时会使用荟萃分析

第一阶段影响因素分配不正确,例如在 Klauer 和 Phye (2008)对“归纳教学”的荟萃分析:达林没有学习成为“归纳”的教学方法,但学习总结了克劳尔的归纳思维培训计划(第 96 页)。

¹在 95% 置信区间的情况下:

(2)从一级荟萃分析确定效应量。如果一级荟萃分析不提供单一的,而是提供多个效应大小估计,例如g. 对于不同的因变量,Hattie 通常将它们组合成每个一级荟萃分析的单一效应量。这里不应该像 Hattie 那样直接从相关性计算算术平均值,而是根据 Fisher (Bortz 2005, p. 219) 从相应的 z 值计算算术平均值。例如,在主题“游戏”的情况下, Hattie在 Spies (1987)的荟萃分析中给出的 $d = 0.26$ 的影响大小对应于 $r = 0.129$ 的相关性;然而,这些值只有在算术平均值是直接相关性 (Spies 1987, p. 5 f.)而不是从 Fisher 的 z 值计算时才会产生。然而,由此产生的不准确性在分析的整体背景下仅具有有限的重要性,因为对于小效应大小,Fisher 相关系数的 z 值偏差小于 1%,中等效应大小约为 3%,仍然小于 10% (见 Bortz 2005, p. 219, Eq. 6.86a) ,并且在 Hattie 的书 中只有 6 个影响因素的平均效应量很大 (Hattie 2009,附录 B)。

(3)从一级荟萃分析中确定效应量估计的方差。翻阅 Visible Learning 的附录 A,可以注意到标准误差中缺失值的比例很高。显然,即使在相应的一级荟萃分析中给出了置信区间,Hattie 也经常无法确定标准误差。由此,可以很容易地计算出标准误差以及效应量估计的方差;另一方面,海蒂抱怨缺乏必要的信息 (2009 年,第 20 页)。例如,在 Sitzmann 及其同事 (2006 年)关于“基于网络的学习”主题的荟萃分析中,除了 95% 置信区间之外,还给出了标准误差 (第 641 页,表 1)。

Hattie 根据一级荟萃分析中效应量标准差的信息计算标准误是不正确的 (参见第 3.1 节)。

例如,在主题“直接指导”的情况下,Hattie 给出的标准误为 0.135,用于 Haas (2005)的荟萃分析,这是由于应用了计算来自主要研究中的标准差和样本量 (cf.

Bortz 2005,第 90 页,方程式。 3.1)。2然而,在固定效应模型的背景下,荟萃分析中效应量估计的标准误差完全基于各个初级研究的效应量估计的标准误差,而这又取决于关于比较条件下的受试者数量和效果大小。在 Haas 的荟萃分析 (2005 年,第 30 页,表 2)中,19 种效应量的汇总值结果

2

0; 592 0; 135

以 0.59 作为标准偏差的值和 19 种效应量 (Haas 2005,第 30 页,表 2)。

0.05 作为标准误差的下限或 0.0025 作为方差的下限,如果假设每项主要研究中近 84 人的纳入研究的平均样本量在

两种情况下分布。海蒂拒绝了这项荟萃分析,其方差为因此,0.018 的重量高达约 7 倍。

(4)重复的中和。对于涉及多个结果的作品
在对同一主题的评论进行总结时,通常会出现问题,即大部分主要研究已经找到了要总结的几篇评论 (参见 Cooper 和 Koenka

2012 年,第 450 页之后)。在迄今为止存在的少数二级荟萃分析中

由于数据重叠,经常使用整体一级荟萃分析
排除在纳入的主要研究之外 (Lipsey and Wilson 1993, p. 1197; Peterson 2001, p. 454),即从 25% 的重叠中排除 (Wilson 和 Lipsey 2001, p. 416) 或三个或更多的主要研究 (Sipe and Curlette 1997, 第 624 页)。另一方面,Hattie 完全忽略了重复的问题,尽管有时重叠明显更大。例如,关于基于网络的学习,15 项主要研究中有 14 项来自 Olson 和 Wisher 荟萃分析

(2002 年,第 11 页),其 0.24 的平均效应大小与结果显着不同

关于同一主题的其他两项荟萃分析 (分别为 0.14 和 0.15),
已经通过其他两个荟萃分析之一 (sitzmann et al. 2006, p. 654 ff.) 覆盖。

(5)效应大小的加权估计。正如 Pant 已经指出的那样
(cf. 2014a, p. 94 f.),Hattie 计算以估计联合效应大小
首先是来自荟萃分析的效果大小的简单算术平均值
步。然而,正确的估计是方差的反比例
效应大小估计的加权算术平均值 (Hedges 和 Olkin
1985 年,第 110 页;博伦斯坦等人。2009 年,第 65 页)。例如,如果有人总结了 Hattie 进行的三项 (总共四项)荟萃分析。
根据给定的值指定标准误差
与方差的倒数部分一起加权,结果是 0.23 的值,而不是 0.59 的效应量估计值。这将看到从第26位降级

在其排名中排名第 98 位。此外,这个效应大小是
Cohen 的标准不超过中等效果并根据 Hattie 的标准

(2009, p. 16 ff.) 不再被归类为绝对相关 (cf.
对此 不同的权重和不同的结果 Pant 2014a, p. 94 f.;
2014b, S. 143 f.)。

(6)效应量估计的标准误差和置信区间 (或显着性检验)的确定。在他的“效果晴雨表”中,海蒂

也是确定效果大小的标准误差。他们的计算是
但是,不正确 (参见 Pant 2014a, p. 96, note 4, 2014b, p. 143, FN 4)。在
通常,给出的值是各个一级荟萃分析的给定标准误差的算术平均值。当谈到“基于查询

例如,指定的标准误差 0.092 是为四个荟萃分析中的两个指定的两个标准误差的算术平均值

从 0.154 到 0.030。两项荟萃分析的估计精度可以
但是,不低于个别荟萃分析的水平;实际上相当于

这两项荟萃分析的效应量估计值的标准误差为 0.029,在主要研究中没有重叠。

同样令人惊讶的是,为什么 Hattie 通常不进行显著性检验或给出效应量估计的置信区间。因此,对于效应量较小的影响因素,是否存在效应仍不清楚。此外,无法确定在排名中占据接近位置的预测变量的相对有效性,因为它们的效应大小的置信区间在大多数情况下可能会重叠,但对于 Hattie 没有给出。由于标准误差的错误信息,它们也不容易被读者确定。

使用示例对 Hattie 程序的详细重构表明,在分析的各个层面都违反了要应用的方法标准。正如给出的一些例子所示,Hattie 的价值观有时过高或过低很多倍。为了能够评估这些缺陷对分析结果的影响,必须正确进行全面分析,正如已经解释的那样,通常缺少必要的信息。然而,所引用的缺点的数量和广度引发了对海蒂结果稳健性的合理怀疑。

3.3 方法论的外部批评

除了关注海蒂本人选择的程序的正确执行的内部批评之外,从外部批评的角度来看,海蒂方法的根本适当性也应该受到质疑。

(1)调节变量的考虑。在他的定量分析中,Hattie 仅采用每个一级荟萃分析的所有主要研究对认知学习结果的平均影响,并使用它来确定每个影响因素的平均影响大小。这被批评为忽视和模糊了调节影响因素影响的变量的作用 (Snook et al. 2009, p. 97; Pant 2014a, p. 93 f., 2014b, p. 142 f.)。Hattie 自己指出了这个问题 (Hattie 2009, p. 9 ff.)。在关于个体影响因素的简短章节中,他通常还处理调节变量的个体特征与效应大小之间的差异。

例如,关于“游戏节目”的主题,他指出“社会戏剧游戏”的效果最高,而“想象力游戏”的效果最低 (Hattie 2009,第 154 页)。但是,他没有给出确切的值 ($r = 0.60$ 或 $d = 1.48$ 对比 $r = 0.14$ 或 $d = 0.28$;Fisher 1992, p. 175, Table 4)。它们也不包含在他的排名中,因此这个列表对于影响因素的特别有效或无效的变体而言意义不大。

然而,在他的二级荟萃分析方法中,最终根本不可能将调节变量考虑在内,因为这些变量通常不会在同一主题的不同一级荟萃分析中统一编码 (cf. Cooper 和 Koenka 2012,第 458 页)。

(2)固定效应模型的充分性。在讨论海蒂的作品时
固定效应模型的适当性也受到质疑 (Pant 2014a,
第 87 页以下)。虽然其中对一个影响因素的所有研究都是一个常数
假设共同效应大小,在所谓的“随机效应模型”中假设“真实”效应大小通常介于

在主要研究中有所不同,因此它们本身就是随机变量的实现
具有一定的概率分布。这个假设是
例如,鉴于通常不同的教学主题,
教育领域各种初级研究中的材料、框架条件等从一开始就比假设一个共同常数更合理

影响。此外,统计同质性检验证明在许多情况下
根据经验,来自主要研究的影响大小差异很大
鉴于恒定的组合效应大小,极不可能
将。与评论家 (Pant 2014a,第 94 页)和 Hattie 的建议相反
本身 (Hattie 2009, p. 12),但这并不一定意味着在
二级荟萃分析水平不可避免地适用于随机效应模型
必须打好基础。虽然在初级研究之间是完全合理的
– 他们不同地实现的方法 – 不同
假设效应量:在极端情况下,每项主要研究估计一个不同的
来自上述随机分布的“真实”效果。在这些情况下
随机效应模型在一级荟萃分析中显示。然而,当几个一级荟萃分析实际上检查同一个主题时

同时应用相同的纳入标准 就像海蒂对许多人的工作一样
的影响因素至少大致如此
令人难以置信的是,各个初级研究的真实效应大小的算术平均值,甚至超出了绘制样本时的抽样误差

初级研究样本应在一级荟萃分析之间有所不同:
然后,所有一级荟萃分析估计相同的平均“真实”效应。
与一些非常广泛的跨主题问题 (Stars et al. 2002, p. 1517 ff.; Tamim et al. 2011, p. 14)相比,其
中
在二级荟萃分析中,随机效应模型不
表明的。除此之外,很大一部分影响因素
Hattie 的工作计算了使用
随机效应模型所需的它们之间的方差估计是不够的,因为每个影响因素平均只有大约 63 次首次荟萃
分析
水平 (参见 Borenstein et al. 2009, p. 163)。

固定效应问题实际上与
在之前对海蒂作品的讨论中有时暗示:如果一个年长的
在固定效应模型中不恰当地进行一级荟萃分析
执行,通常会低估标准误差
中等效应量,因为未考虑主要研究之间的差异。此外,主要研究随后被错误地加权,因为

原始研究之间效应量的差异越大,原始研究的样本量在随机效应模型中所起的作用越小

(参见 Pant 2014a, p. 87 ff.)。目前还没有确定的方法直接根据一级荟萃分析的统计信息纠正二级荟萃分析中的这些缺陷。的方差

相反,主要研究之间的效应大小可以基于从每项主要研究估计的效应量估计值的差异前提是这些是在样本量信息的帮助下确定的(Borenstein 等人, 2009 年,第 72 页)。然而,这种方法已经等同于对主要研究数据的重新分析(参见 Cooper 和 Koenka 2012,第 458 页)。此外,由于主要研究效应大小的错误加权随后不能在一级荟萃分析中纠正也将是这需要重新总结主要研究效果大小。

首先在荟萃分析中不恰当地使用固定效应模型舞台不属于海蒂。但它构成了不可逾越的障碍介绍了他对二级荟萃分析的方法,仅使用一级荟萃分析的结果。另一方面,我们的解释表明

来自所有现有一级荟萃分析的主要研究数据 如果可用 - 将被汇总并进行综合荟萃分析第一级(参见 Cooper 和 Koenka 2012,第 458 页)。这将使同质性检验、随机效应模型的正确应用以及促进主持人分析或首先使它们成为可能。此外,您还可以这样也解决了上面提到的重复问题。我们将在最后一节中回到此过程的先决条件。

(3)影响因素比较。除了这些批评,所有关于 138 个影响因素的个体二级荟萃分析相关的,也是这些影响因素之间比较的意义,正如有效性排名所建议的那样(Hattie 2009,附件 B)。

变成质疑。首先是a的效果大小之间的关系影响其“持续时间”的因素。在这方面,通常与“一学年教学效果”进行比较,即 0.15 或

0.2 至 0.4 (Hattie 2009,第 16 页;Terhart 2011,第 428 页;Pant 2014b, p. 142) - 每学期最多 0.2 到 0.4 (Köller 2012, p. 74)。尽管这些参考值在比较学校表现研究中是有意义的(例如 Roppelt et al. 2013, p. 124 ff.) ,它们可用作帽子的分类辅助影响因素误导。例如,在实验教学和学习研究中,支持的教学形式的效果,例如B.

在最多三个的单个会话中制定的解决方案示例小时持续时间检查。观察到的效果大小例如显然,0.3 几乎不对应于一学年课程中能力提升的幅度。致力于更全面的计划,例如

看看海蒂归类为“直接指示”的调查另一方面,措施的效果持续长达一年(怀特 1988 年,第 371 页)。很明显,在提到的两个研究领域,用于记录学习成功的工具在范围上有所不同所涵盖的主题会有很大差异。因此,不能从以这种方式确定的效果强度得出任何可靠的结论,这意味着之间的比较证明这两种不同类型的教学措施的合理性

将是:两者都没有获得指导形式的支持,例如制定样本解决方案,在持续约一个半小时的实验室实验中可能确定了约 0.6 的效应大小(参见 Hattie 2009, 第 172 页),在每周四节课的两周以上的数学课中使用时,其效果必然为 2.4 左右,在这种情况下,效果大小也不一定在 0.6 左右。如果在较长时间内将制定的解决方案示例集成到课程中,并且与在此期间处理的所有内容相关的学习成功仅在最后进行测试,则它更有可能更低。因此,即使在效果强度的基础上,也无法比较具有完全不同典型持续时间的措施的有效性。

其次,Hattie 的排名表明,138 个影响因素应被视为从根本上替代的可能行动方案,从中选择最有效的一个,例如在设计课程时。

然而,这将假定影响因素是行动的实际选择,并且它们的影响大小是根据相同的“基线”确定的,即所有包括的一级荟萃分析中的主要研究中的控制条件是被视为等效的比较标准。从排名来看,这既不是事实,也不是不可能,因为影响因素属于完全不同的类型:一方面,有学校规模等制度框架条件(Hattie 2009, p. 79 f.)和个人特征,如自我概念(Hattie 2009, p. 46 f.)综合项目,如归类为“直接指导”的项目(Hattie 2009, p. 204 ff.),其中规定的效果大小通常基于与某种形式的“传统”课程进行比较。由于有共同的参考点,它们的效果大小绝对可以作为根据它们的有效性对这些类型的程序进行排名的基础。另一方面,排名列表中包含了对同一测量的某些设计参数的设计变体的比较(参见 Renkl 2015, p. 80 ff.),例如,关于练习主题,比较集中在一次锻炼和多次锻炼的分布式练习(“间隔练习与大规模练习”,Hattie 2009, 第 185 页)。哈蒂的排名有点像德甲联赛,拜仁慕尼黑和汉堡 SV 在好日子和坏日子里都有一席之地。值得怀疑的是,教师是否必须在直接“教学”和分布式实践领域的计划之间做出明智的决定,而不是两者的最佳组合。如果是这种情况,那么对这些行动选项的相对有效性的评估就不可能基于与一种情况下的教学“标准条件”的比较以及与同一指令形式的另一种设计变体的比较在另一种情况下。

4 后果

我们对数据基础的质量、Hattie 方法所产生的方法学要求的实现以及基本原理的评论

这种方法的充分性表明了一个相当明确的结论：很大一部分

调查结果受到合理怀疑。正如我们所展示的，它们是

关于单个荟萃分析的影响大小和标准误差的信息

附录 A 以及由此产生的效应量和标准误

所有“影响大小晴雨表”和附录 B 中的影响因素都不是

可靠的。由于计数单位不明确和重叠，这同样适用

纳入的主要研究的研究数量、影响和人员在这两个层面上。⁴因此，几乎所有的物种都包含在工作中

受缺陷影响的定量信息。非常好听

然而，Hattie 本人（Beywl 和 Zierer 2015a, p. XXVII）以及在关于他的工作的讨论中（例如

Arnold 2011, p. 220）部分持有相同的观点

个人确定的效果大小最终不是决定性的。的

这部作品的真正价值在于“约翰·海蒂的故事或理论”

开发”（Beywl 和 Zierer 2015a, 第 XXVIII 页）。原则上，如果它是独立的，它并不能很好地反映科学理论的内容

的实证结果应该持续下去。此外，如果分析的每个级别都存在缺陷，则基于它们的内容

结论 例如关于深度而不是表面特征或教学而不是学校系统特征的重要性（参见 Köller 2012,

第 77 页）有问题。当然，这并不意味着这些特性没有

具有首要的重要性。但是，这意味着关于此的此类问题

根本无法确定依据。

尽管如此，在我们看来，海蒂的开创性工作为他赢得了宝贵而持久的优点。它们主要在于他

还指出了尽管进行了大量的实证研究，但仍然存在的东西

不可能：对经验的全面和科学合理的综合

教育研究。

在这样做的过程中，他提请注意一个基本问题

实证教育研究：公共资源在全球范围内不断被用于研究 结果往往不是

如果没有发现统计上显著的影响，则予以公布。

公共资源也流入荟萃分析，有时它们不会

一旦明确了哪些主要研究被包括在内（例如，Johnson and Johnson 1987），或者主要研究表不存在或提供的主要研究信息不足。

正如海蒂的工作所表明的那样，单一的荟萃分析可以回答以下问题：

然而，一个影响因素的有效性无论如何都无法得出结论性的答案。

因此，如果数量很大，则应更新荟萃分析

⁴附录 A 中最初系统错误计算的通用语言效应量

德语翻译中低于 0% 和高于 100% 的不可能概率已得到纠正（Beywl 和 Zierer 2015b, 第 XVII 页）。

其他初级研究,但不是 如海蒂的工作
在二级荟萃分析中,但作为一级荟萃分析
所有没有重复的现有主要研究的基础,包括早期荟萃分析中包含的那些 (cf. Cooper and Koenka 2012, p. 458 f.)。旁边
就效应大小的统一衡量达成一致,该衡量标准正在逐渐改变
Hedges 的标准化均值差的无偏估计量 (Hedges 和 Olkin 1985, p. 81) 并符合既定的处理标准
具有统计相关性,用于正确加权和计算
标准误差 (Borenstein et al. 2009, p. 65 ff.)对我们来说似乎很紧迫,
每次荟萃分析都会发布完整且结构清晰的主要研究表,可用于更新

(Cooper 和 Koenka 2012,第 458 页)。

如果初级研究超出期刊文章的少数读者

应该为知识的科学进步做出持久的贡献

他们通过提供标准化形式的“原始元分析数据”来促进像海蒂这样的项目,而不是在期刊上发表

公开。特别是在研究中,由于缺乏

具有统计学意义的影响在期刊上发表的机会很小,相关参数可以与

该方法的可理解文档被传输到中央数据库,因此永久存档并用于荟萃分析,无需任何进一步的努力

可以使用。建立用于归档原始数据的基础设施的努力表明,此类

服务也必须作为适合发布列表的产品获得奖励

(Stanat 2012,第 8 页)。我们认为此类数据库的结构

面向未来,因为它是紧迫的。因此,可以显着减少由选择性发表研究结果引起的扭曲,并且对个别发现的元分析总结变得更加容易。通过

Hattie 创新理念的进一步发展可能源于一个有远见的人

方法成为研究型教育实践的有形部分。

附录

非重叠荟萃分析等效性的证据

在固定效应模型框架内对所有主要研究进行荟萃分析的荟萃分析

(i) 在固定效应模型中,所有初级研究 d 的综合效应量根据 k 个初级研究的效应量 d_i 估计如下:

$$d = \frac{\sum_{i=1}^k w_i d_i}{\sum_{i=1}^k w_i} \quad (1)$$

(cf. Borenstein et al. 2009, p. 66, Formula 11.3) with $w_i = 1/v_i$ (cf. Borenstein et al. 2009, p. 63, 公式 11.2) 来自主要研究 i 中效应大小的方差 v_i 。

以下适用于该估计值的方差 vd :

$$vd = \frac{1}{\sum_{i=1}^k w_i} \quad (2)$$

(参见 Borenstein 等人 2009, 第 66 页, 公式 11.4)。

如果 k 个主要研究来自 m 个荟萃分析, 每个都有 k_j 个主要研究 (荟萃分析之间没有重叠), 效应量为 d_{ji} , 估计值是所有主要研究的组合效应量

$$d_j = \frac{\sum_{i=1}^{k_j} w_{ji} d_{ji}}{\sum_{i=1}^{k_j} w_{ji}} \quad (3)$$

和我们一起 d_j 来自主要研究 i 中效应大小的方差 v_{ji} 来自 Meta 分析 j 及其方差

$$vd_j = \frac{1}{\sum_{i=1}^{k_j} w_{ji}} \quad (4)$$

(ii) 在每个荟萃分析 j 中, 主要研究的综合效应量是根据效应量 d_{ji} 和将 (1) 应用于其中包含的所有 k_j 的权重 w_{ji} 计算的

$$d_j = \frac{\sum_{i=1}^{k_j} w_{ji} d_{ji}}{\sum_{i=1}^{k_j} w_{ji}} \quad (5)$$

并使用 (2) 它的方差

$$vd_j = \frac{1}{\sum_{i=1}^{k_j} w_{ji}} \quad (6)$$

确实。

(iii) 如果从m个荟萃分析中的每一个中估计出共同的效应大小及其方差,所有初级研究的共同效应大小也可以直接从估计值d_j和来自m个荟萃分析的权重w_j估计:

$$\frac{\sum_{j=1}^m w_j d_j}{\sum_{j=1}^m w_j} \tag{7}$$

和

$$w_j D_{vj} = \frac{1}{\sum_{k=1}^m w_k} \sum_{k=1}^m w_k d_k \tag{8}$$

(因为 (6))。

为了证明(7)在 (7) 的右边为w_j把右边的 (8)的一侧和对于d_j (5)的右侧是通过缩短获得的在分子内部并且由于 (3) :

$$\frac{\sum_{j=1}^m \frac{w_j d_j}{\sum_{k=1}^m w_k}}{\sum_{j=1}^m w_j} = \frac{\sum_{j=1}^m \frac{w_j d_j}{\sum_{k=1}^m w_k}}{\sum_{j=1}^m w_j} \quad \text{嘀嗒}$$

联合效应大小估计的方差变为如下决定:

$$v_d = \frac{1}{\sum_{j=1}^m w_j} \tag{9}$$

为了证明(9)在 (9) 的右边为w_j把右边的 (8)的一侧,由于(4) 得到:

$$\frac{1}{\sum_{j=1}^m w_j} = \frac{1}{\sum_{j=1}^m \frac{w_j}{\sum_{k=1}^m w_k}} \quad \text{视频_}$$

因此,可以估计来自m个荟萃分析的所有主要研究的综合效应大小,而不会在主要研究中重叠:

荟萃分析本身被视为主要研究并在进一步的荟萃分析中根据固定效应模型进行总结。

文学

阿诺德一世 (2011 年)。 John Hattie:可见学习:与 achie 相关的 800 多项元分析的综合
旺旺。国际教育评论, 57,219-221。
Beywl, W. 和 Zierer, K. (2015a)。使学习可见扩展:扩展版的前言。在J
海蒂,让学习可见:可见学习的德语修订版 (第 10 页)。
二十七-二十九)。 Baltmannsweiler 施耐德Hohengehren。

Beywl, W. 和 Zierer, K. (2015b). 让学习可见:关于“可见学习”的德语版。在 J. Hattie, 使学习可见:可见学习的德语修订版 (第 VI-XXVI 页)。Baltmannsweiler:施耐德Hohengehren。

Borenstein, M., Hedges, LV, Higgins, JPT, & Rothstein, HR (2009)。荟萃分析导论。
奇切斯特:威利。

Bortz, J. (2005)。人类和社会科学家统计 (第 6 版)。海德堡:斯普林格。

Brügelmann, H. (2014)。根据海蒂的说法:越频繁越好?关于“循证”对现场教学行动的重要性。在 E. Terhart (ed.), The Hattie study under Discussion: making questions visible (pp. 38–50)。塞尔策:克莱特-卡尔迈耶。

Cooper, H. 和 Koenka, AC (2012)。评论概述:当研究综合成为新综合学术的主要要素时,独特的挑战和机遇。美国心理学家, 67 (6), 446–462。

丹斯基, JL (1980)。Make-believe:游戏和联想流畅度之间关系的中介。
儿童发展, 51 (2), 576–579。

多诺万, JJ 和拉多塞维奇, DJ (1999 年)。对练习效果分布的荟萃分析回顾:现在你看到了,现在你没有。应用心理学杂志, 84 (5), 795–805。

Eisenstaedt, RS, Barry, WE 和 Glanz, K. (1990)。基于问题的学习:随机选择的参与者和下降者的认知保留和队列特征。学术医学, 65 (9), S11–S12。

费舍尔, EP (1992 年)。游戏对发展的影响:荟萃分析。游戏与文化, 5, 159–181。

Gijbels, D., Dochy, F., van den Bossche, P. 和 Segers, M. (2005)。基于问题的学习的效果:从评估的角度进行荟萃分析。教育研究回顾, 75 (1), 27–61。

哈斯, M. (2005 年)。二次代数的教学方法:结果的荟萃分析。NASSP 公告, 89 (642), 24–46。

海蒂, 江淮汽车 (2009)。可见学习:综合 800 多项与成就相关的荟萃分析。
伦敦:劳特里奇。

Hedges, LV 和 Olkin, I. (1985)。荟萃分析的统计方法。圣地亚哥:学术出版社。

Horton, PB, McConney, AA, Gallo, M., Woods, AL, Senn, GJ, & Hamelin, D. (1993)。调查概念图作为教学工具的有效性。
科学教育, 77 (1), 95–111。

约翰逊, DW 和约翰逊, RT (1987 年)。研究表明成人合作的好处。教育
领导, 45 (3), 27–30。

Klauer, KJ 和 Phye, GD (2008)。归纳推理:一种训练方法。教育研究回顾, 78 (1), 85–123。

Koller, O. (2012)。什么在学校最有效?海蒂关于学校和教学变量对学校表现影响的研究结果。教育心理学, 59 (1), 72–78。

Lee, TD 和 Genovese, ED (1988)。运动技能习得的实践分布:重新考虑学习和表现的影响。运动与运动研究季刊, 59 (4), 277–287。

Levie, WH 和 Lentz, R. (1982)。文字插图的效果:研究综述。教育公社
国家与技术杂志, 30 (4), 195–232。

Lipsey, MW 和 Wilson, DB (1993)。心理、教育和行为治疗的功效:荟萃分析的证实。美国心理学家, 48 (12), 1181–1209。

Lipsey, MW 和 Wilson, DB (1995)。回复关于 Lipsey 和 Wilson (1993) 的评论。美国心理学家
chologist, 50, 113–115。

Nesbit, JC, & Adesope, OO (2006)。使用概念和知识图学习:荟萃分析。
教育研究回顾, 76 (3), 413–448。

Olson, TM 和 Wisher, RA (2002)。基于网络的教的有效性:初步调查。国际开放和远程学习研究评论, 3 (2), 1–17。

裤子, HA (2014a)。教育政策和教学决策证据的处理:教育研究中的元分析。在 R. Bromme & M. Prenzel (eds.), 从研究到基于
证据的决策:实证教育研究的呈现和公众理解 (教育科学杂志:特刊 27, 第 79–99 页)。威斯巴登:斯普林格 VS。

裤子, HA (2014b)。可见证据?对 John Hattie 的 meta-meta 分析进行有条不紊的检查。在 E. Terhart (ed.), The Hattie
study under Discussion: Making questions visible (pp. 134–146)。塞尔策:克莱特-卡尔迈耶。

彼得森, RA (2001)。论大学生在社会科学研究中的运用:来自第二个视角的启示
顺序荟萃分析。消费者研究杂志, 28 (3), 450–461。

Renkl, A. (2015)。不同的道路通向罗马:基于原则的认知技能案例。学习:
研究与实践, 1 (1), 79–90。

Roppelt, A., Plenk, C., Pöhlmann, C. 和 Pietsch, E. (2013)。国家数学比较。在 HA Pant, P Stanat, U Schroeders, A Roppelt, T Siegle 和 C Pöhlmann (编辑), IQB 国家比较 2012: 中学 I 结束时的数学和科学技能 (第 123-140 页)。芒斯特: 韦克斯曼。

罗森塔尔, R. (1994)。效应大小的参数测量。在 H. Cooper 和 LV Hedges (Hrsg.), 研究综合手册 (S. 231-244)。纽约: 罗素圣人基金会。

Sipe, TA, & Curlette, WL (1997)。与教育成就相关的因素的综合综合: 总结和综合综合分析的方法。国际教育研究杂志, 25 (7), 573-698。

Sitzman, T., Kraiger, K., Stewart, D., & Wisher, R. (2006)。基于网络和课堂教学的比较有效性: 荟萃分析。人事心理学, 59, 623-664。

Snook, I., O'Neill, J., Clark, J., O'Neill, A.-M. 和 Openshaw, R. (2009)。无形的学习? 对约翰·海蒂 (John Hattie) 的书的评论: 可见学习: 综合 800 多项与成就相关的荟萃分析。新西兰教育研究杂志, 44 (1), 93-106。

Sohn, D. (1995)。元分析作为一种发现手段。美国心理学家, 50, 108-110。

间谍, C. (1987 年)。幼儿的玩耍、解决问题和创造力。Vortrag auf dem 儿童发展研究协会双年度会议, 巴尔的摩, 1987 年 4 月 23 日至 26 日。

斯塔纳特, P. (2012 年)。在教育研究中提供和使用定量研究数据: DFG 的“教育科学”审查委员会的备忘录。 http://www.dfg.de/download/pdf/foerderung/basisn_dfg_foerderung/informationen_fachwissenschaften/geisteswissenschaften/forschungsdaten_memorandum_fk_109.pdf。 _ 2015 年 2 月 5 日访问。

Sterne, JAC, Jüni, P., Schulz, KF, Altman, DG, Bartlett, C., & Egger, M. (2002)。在元流行病学研究中评估研究特征对治疗效果影响的统计方法。医学统计, 21 (11), 1513-1524。

Tamim, RM, Bernard, RM, Borokhovski, E., Abrami, PC 和 Schmid, RF (2011)。四十年的研究表明技术对学习的影响: 二阶元分析和验证研究。教育研究回顾, 81 (1), 4-28。

Terhart, E. (2011)。约翰·海蒂真的找到了教学研究的圣杯吗? 扩展审查“可见学习”。课程研究杂志, 43 (3), 425-438。

怀特, WAT (1988 年)。特殊教育中直接教学效果的荟萃分析。儿童教育和治疗, 11 (4), 364-374。

Wilson, DB 和 Lipsey, MW (2001)。方法在治疗有效性研究中的作用: 证据从荟萃分析。心理方法, 6 (4), 413-429。